

# Tech Challenge — Fase 1 (IADT)

Sistema de Apoio ao Diagnóstico em Saúde da Mulher  
Câncer de Mama: Machine Learning, Stacking e Visão Computacional

---

**Aluno:** Eduardo Costalonga

**Curso:** IADT — FIAP

**Repositório Git:** \_\_\_\_\_

**Vídeo de demonstração:** \_\_\_\_\_

---

## 1. Introdução e objetivo

Uma rede de hospitais especializados no atendimento à mulher busca um sistema inteligente de suporte ao diagnóstico e detecção de riscos. Construímos a base de um sistema de Machine Learning para **classificação de câncer de mama** (maligno vs. benigno) a partir de dados estruturados, e, como item extra, um classificador de **mamografias** com CNN. O câncer de mama é uma das principais causas de mortalidade feminina; a detecção precoce salva vidas.

## 2. Datasets

**Breast Cancer Wisconsin** — 569 casos, 30 features numéricas do núcleo celular, alvo **diagnosis** (M/B). **CBIS-DDSM** (extra) — 3.566 recortes de lesão de mamografias rotulados, com split oficial treino/teste (2.862 / 704).

## 3. Análise exploratória (EDA)

Distribuição moderadamente desbalanceada: 357 benignos (62,7%) e 212 malignos (37,3%). As features de tamanho e irregularidade do núcleo (concave points, perimeter\_worst, radius\_worst, area\_worst) são as mais correlacionadas com malignidade.




Figura 1 — Distribuição do diagnóstico.




Figura 2 — Correlação das features com o diagnóstico.

## 4. Pré-processamento

Pipeline scikit-learn: remoção de colunas não-informativas; codificação do alvo (M=1, B=0); split estratificado 80/20 (455 treino / 114 teste); padronização com StandardScaler dentro de um Pipeline (ajustado só no treino, evitando data leakage).

## 5. Modelagem — 6 modelos + Stacking

Seis modelos de base cobrindo todos os paradigmas — Regressão Logística (linear), Árvore (regras), KNN (distância), Random Forest e Gradient Boosting (ensembles) e SVM (margem) — e um **Stacking** que os combina com um meta-modelo, usando validação cruzada interna (5-fold).

## 6. Resultados e avaliação

**Métrica prioritária: recall da classe maligna** — o pior erro é o falso negativo. As duas últimas colunas trazem a validação cruzada 5-fold.

| Modelo              | Accuracy | Recall | F1    | CV Acc | CV Recall |
|---------------------|----------|--------|-------|--------|-----------|
| Stacking            | 0,983    | 0,952  | 0,976 | 0,976  | 0,959     |
| SVM                 | 0,974    | 0,929  | 0,963 | 0,974  | 0,953     |
| Random Forest       | 0,974    | 0,929  | 0,963 | 0,958  | 0,935     |
| Regressão Logística | 0,965    | 0,929  | 0,951 | 0,971  | 0,947     |
| Gradient Boosting   | 0,965    | 0,905  | 0,950 | 0,954  | 0,935     |
| KNN                 | 0,956    | 0,905  | 0,938 | 0,963  | 0,918     |
| Árvore de Decisão   | 0,921    | 0,833  | 0,886 | 0,934  | 0,888     |

O **Stacking** venceu em todas as métricas (AUC 0,995; apenas 2 erros em 114 casos). Para produção, a Regressão Logística segue atraente pela interpretabilidade.




Figura 3 — Matriz de confusão do Stacking (teste).




Figura 4 — Curvas ROC dos modelos estruturados (AUC).

## 7. Ajuste de limiar orientado ao recall (finalidade clínica)

Um modelo médico não deve ser julgado só pela acurácia: é preciso **definir sua finalidade** — aqui, **não deixar passar um câncer**. Ajustando o limiar de decisão (padrão 0,5), controlamos o trade-off entre os quadrantes da matriz de confusão.

| Limiar               | Falsos negativos | Falsos positivos |
|----------------------|------------------|------------------|
| 0,50 (padrão)        | 2                | 0                |
| 0,02 (recall = 100%) | 0                | 18               |

Para **eliminar todos os falsos negativos**, o custo é 18 falsos positivos (exames de confirmação). Em triagem, é um custo aceitável. A acurácia mais baixa não é piora: é uma **escolha consciente alinhada à finalidade**.

Matriz de confusao: limiar padrao vs. priorizando recall




Figura 5 — Limiar padrão (2 FN) vs. priorizando recall (0 FN).




Figura 6 — Trade-off recall × precisão × F1 por limiar.

## 8. Explicabilidade

Feature importance (coeficientes da Regressão Logística) e SHAP (Árvore) convergem: `perimeter_worst`, `concave points_worst` e `area_worst` são as mais determinantes — coerente com o conhecimento clínico.




Figura 7 — Importância das features (Regressão Logística).




Figura 8 — Valores SHAP (Árvore de Decisão).

## 9. Fase extra — Visão Computacional (CNN)

Classificação de mamografias (CBIS-DDSM) com transfer learning em PyTorch (GPU), treino em duas fases (warmup + fine-tuning). Comparamos quatro arquiteturas pré-treinadas:

| Arquitetura          | Accuracy | Recall (maligno) | F1 (maligno) |
|----------------------|----------|------------------|--------------|
| ResNet18 (escolhida) | 0,642    | 0,746            | 0,621        |
| DenseNet121          | 0,644    | 0,736            | 0,618        |
| EfficientNet-B0      | 0,668    | 0,703            | 0,624        |
| MobileNetV2          | 0,675    | 0,696            | 0,626        |

As quatro ficaram muito próximas — o gargalo é a dificuldade da tarefa, não a arquitetura. Coerente com a métrica prioritária (recall), escolhemos a **ResNet18** (maior recall, 0,746).




Figura 9 — Comparação das arquiteturas de CNN.




Figura 10 — Matriz de confusão da CNN escolhida (ResNet18).



## 10. Experimento — Radiômica + ML clássico vs. CNN

Testamos: e se, em vez de uma CNN, extrairmos features numéricas das mamografias e usarmos o nosso Stacking? Extraímos **76 features** de cada recorte (intensidade, textura GLCM, LBP, Gabor, gradiente/bordas e forma da lesão) e treinamos os modelos com `class_weight` balanceado e ajuste de limiar — comparação justa (mesma prioridade de recall).

| Abordagem                     | Recall (maligno) | F1 (maligno) | AUC   |
|-------------------------------|------------------|--------------|-------|
| CNN (ResNet18)                | 0,746            | 0,621        | -     |
| Radiômica - SVM (melhor F1)   | 0,710            | 0,567        | 0,625 |
| Radiômica - Gradient Boosting | 0,460            | 0,488        | 0,644 |
| Radiômica - Stacking          | 0,428            | 0,464        | 0,638 |

**A CNN venceu, e o AUC explica por quê.** O balanceamento elevou o recall da radiômica, mas o AUC ficou preso em ~0,60-0,64 mesmo com 76 features ricas — o AUC mede o sinal real de separação, e batemos no teto do que features feitas à mão extraem desses recortes. A radiômica só alcança recall alto sacrificando a precisão de forma inviável. **Conclusão:** nesta tarefa, a CNN aprende representações melhores dos pixels do que conseguimos projetar manualmente — resultado honesto que embasa, com evidência, a escolha do deep learning para as imagens.




Figura 11 — Radiômica + ML clássico vs. CNN nas mesmas mamografias.

## 11. Sistema multimodal — roteamento por modalidade

As duas bases são de **pacientes diferentes**, então não há fusão dos resultados num único número. A solução correta é um **roteador por modalidade** (`diagnosticar()`): recebe *ou* um exame tabular *ou* uma imagem, reconhece o tipo e encaminha para o modelo especialista, devolvendo um laudo padronizado. Demonstrado no notebook de estudo integrado. **Trabalho futuro:** a fusão multimodal real exigiria um dataset com as duas modalidades da mesma paciente.

## 12. Discussão crítica

O sistema é uma **ferramenta de apoio e triagem — nunca substituto do médico**. Pontos fortes: alto desempenho e robustez (validação cruzada), interpretabilidade (SHAP), controle explícito do trade-off pela finalidade clínica. Limitações: bases curadas e de fonte única — o desempenho real seria menor, exigindo validação externa. O diagnóstico final é sempre do médico.

## 13. Como executar

```
pip install -e .
python -m techchallenge # módulo estruturado completo
python -m techchallenge --comparar-cnn # treina e compara as CNNs
python -m techchallenge.cli.extrair_radiomica / .treinar_radiomica # radiômica
```

Ao processar, o sistema limpa automaticamente os resultados antigos e regenera. Detalhes no README.md; relatório técnico completo em docs/RELATORIO\_TECNICO.md.

## 14. Entregáveis

- Código-fonte (pacote techchallenge, notebooks e CLIs).
- README.md com instruções.
- Dataset estruturado incluído; imagens do CBIS-DDSM via download.
- Resultados (gráficos, métricas, modelos) em outputs/.
- Relatório técnico (docs/RELATORIO\_TECNICO.md) e roteiro do vídeo (docs/ROTEIRO\_VIDEO.md).
- Documento didático dos modelos (Explicacao\_Modelos\_ML.docx).

**Repositório Git:** \_\_\_\_\_

**Vídeo de demonstração:** \_\_\_\_\_